

Proyecto_Final_Integrado

August 31, 2026

1 Proyecto Final — DataXperience

2 ¿Qué hace que un portátil sea caro?

Universidad EAN · Ciencia de Datos Docente: Camila Silva

Integrante	Etapas a cargo
Brayan Felipe Alvarez Nieto	Etapas 1 — Preparación de datos
Jhonatan Stiben Rey Velasquez	Etapas 2 — Análisis estadístico
Andres Sebastian Quintana Morales	Etapas 3 — Visualización y modelado

2.1 De qué se trata

Analizamos un conjunto de 1.303 computadores portátiles con sus especificaciones técnicas y su precio de venta, para responder una pregunta concreta: **¿qué características explican el precio de un portátil, y se puede predecir ese precio a partir de sus especificaciones?**

El trabajo va en tres etapas. Primero dejamos los datos utilizables, porque venían casi todos como texto. Después analizamos cómo se comportan. Y por último construimos un modelo que predice el precio y vemos para qué sirve.

Dataset: [Laptop Price — Kaggle](#)

2.2 Antes de ejecutar

Este cuaderno corre de principio a fin desde el archivo original. Solo hay que subir `laptop_price.csv` al panel de archivos de la sesión (el ícono de carpeta a la izquierda). El archivo está en la carpeta `data/` del repositorio.

3 ETAPA 1 — Preparación de datos

A cargo de: Brayan Felipe Alvarez Nieto

Elegimos el conjunto de datos, revisamos en qué estado viene y lo dejamos listo para poder analizarlo.

3.1 1.1 ¿Por qué este dataset?

Escogimos un dataset de precios de portátiles que cuenta con 1.303 equipos y sus respectivas especificaciones técnicas, como marca, procesador, memoria RAM, almacenamiento, pantalla, peso y precio. Lo seleccionamos porque contiene suficiente información para aplicar los conocimientos adquiridos a lo largo del curso y realizar diferentes procesos de análisis y tratamiento de datos. Además, tenemos cierto conocimiento sobre las características de los equipos presentados, lo que nos permite interpretar los datos de una manera más sencilla y comprender mejor los resultados obtenidos.

La pregunta que queremos responder es: ¿qué características hacen que un portátil sea más caro, y se puede predecir el precio a partir de sus especificaciones?

3.2 1.2 Cargamos las librerías y el archivo

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_style("whitegrid")

df = pd.read_csv('laptop_price.csv', encoding='latin-1')
df.head()
```

```
[1]:  laptop_ID Company      Product  TypeName  Inches  \
0         1   Apple  MacBook Pro  Ultrabook   13.3
1         2   Apple  Macbook Air  Ultrabook   13.3
2         3     HP      250 G6    Notebook   15.6
3         4   Apple  MacBook Pro  Ultrabook   15.4
4         5   Apple  MacBook Pro  Ultrabook   13.3

      ScreenResolution      Cpu  Ram  \
0  IPS Panel Retina Display 2560x1600  Intel Core i5 2.3GHz  8GB
1                                1440x900  Intel Core i5 1.8GHz  8GB
2              Full HD 1920x1080  Intel Core i5 7200U 2.5GHz  8GB
3  IPS Panel Retina Display 2880x1800  Intel Core i7 2.7GHz 16GB
4  IPS Panel Retina Display 2560x1600  Intel Core i5 3.1GHz  8GB

      Memory      Gpu  OpSys  Weight  \
0      128GB SSD  Intel Iris Plus Graphics 640  macOS  1.37kg
1  128GB Flash Storage      Intel HD Graphics 6000  macOS  1.34kg
2      256GB SSD      Intel HD Graphics 620  No OS  1.86kg
3      512GB SSD      AMD Radeon Pro 455  macOS  1.83kg
4      256GB SSD  Intel Iris Plus Graphics 650  macOS  1.37kg

      Price_euros
0      1339.69
```

1	898.94
2	575.00
3	2537.45
4	1803.60

El archivo hay que leerlo con `encoding='latin-1'`. Con el encoding normal daba error porque algunos nombres de producto tienen tildes.

3.3 1.3 ¿Cómo vienen los datos?

Antes de tocar nada, miramos qué tenemos: cuántas filas, qué tipo es cada columna, si hay datos faltantes y si hay filas repetidas.

```
[2]: print("Dimensiones:", df.shape)
print("\n--- Tipos de dato ---")
print(df.dtypes)
print("\n--- Nulos por columna ---")
print(df.isnull().sum())
print("\n--- Filas duplicadas ---")
print(df.duplicated().sum())
print("\n--- Duplicadas sin contar el ID ---")
print(df.drop(columns=['laptop_ID']).duplicated().sum())
```

Dimensiones: (1303, 13)

--- Tipos de dato ---

laptop_ID	int64
Company	object
Product	object
TypeName	object
Inches	float64
ScreenResolution	object
Cpu	object
Ram	object
Memory	object
Gpu	object
OpSys	object
Weight	object
Price_euros	float64
dtype:	object

--- Nulos por columna ---

laptop_ID	0
Company	0
Product	0
TypeName	0
Inches	0
ScreenResolution	0

```
Cpu          0
Ram          0
Memory       0
Gpu          0
OpSys        0
Weight       0
Price_euros  0
dtype: int64
```

```
--- Filas duplicadas ---
0
```

```
--- Duplicadas sin contar el ID ---
28
```

3.3.1 Lo que encontramos

No hay nulos ni duplicados, o sea que por ese lado el dataset viene bien. Pero el problema es otro: casi todas las columnas son de tipo `object`, o sea texto, incluso las que deberían ser números.

Por ejemplo:

- Ram dice "8GB" en vez de 8
- Weight dice "1.37kg" en vez de 1.37
- Memory dice cosas como "128GB SSD + 1TB HDD"
- ScreenResolution mete el tipo de panel, si es táctil y la resolución, todo junto
- Cpu y Gpu traen el modelo exacto, que es demasiado específico

Así como está no podemos ni sacar el promedio de la RAM. Entonces la limpieza de este proyecto no es rellenar huecos, es convertir todo ese texto en números y categorías que sí sirvan.

Sobre las filas duplicadas: contando el `laptop_ID` no hay ninguna, pero al ignorarlo aparecen 28 filas repetidas. Las revisamos y son equipos con exactamente las mismas especificaciones y el mismo precio, por ejemplo tres Acer de 15.6 pulgadas a 289 euros.

Decidimos no eliminarlas. No parecen errores de captura sino el mismo modelo listado varias veces en el catálogo, que es información real del mercado: si un modelo se repite es porque hay varias unidades a la venta. Borrarlas sesgaría el análisis hacia los equipos raros. Después de agrupar categorías el número sube a 30, porque dos equipos que se diferenciaban solo por el sistema operativo quedan idénticos al agruparlos.

3.4 1.4 Limpieza

3.4.1 1.4.1 Ram y Weight

Son números con la unidad pegada. Quitamos el "GB" y el "kg" y ya.

```
[3]: df['Ram_GB'] = df['Ram'].str.replace('GB', '', regex=False).astype(int)
df['Weight_kg'] = df['Weight'].str.replace('kg', '', regex=False).astype(float)

print(df[['Ram', 'Ram_GB', 'Weight', 'Weight_kg']].head())
```

	Ram	Ram_GB	Weight	Weight_kg
0	8GB	8	1.37kg	1.37
1	8GB	8	1.34kg	1.34
2	8GB	8	1.86kg	1.86
3	16GB	16	1.83kg	1.83
4	8GB	8	1.37kg	1.37

3.4.2 1.4.2 ScreenResolution

Esta columna trae tres cosas mezcladas: si el panel es IPS, si la pantalla es táctil, y la resolución. Las separamos en columnas distintas.

Además calculamos el PPI (píxeles por pulgada). Lo hicimos porque dos portátiles de 15 pulgadas pueden tener pantallas muy distintas: uno a 1366x768 y otro a 1920x1080. El tamaño solo no dice nada de la calidad, el PPI sí.

```
[4]: sr = df['ScreenResolution']

df['Touchscreen'] = sr.str.contains('Touchscreen').astype(int)
df['IPS'] = sr.str.contains('IPS').astype(int)

# sacamos los dos números de la resolución (ej: 1920x1080)
res = sr.str.extract(r'(\d+)x(\d+)').astype(int)
df['Res_X'] = res[0]
df['Res_Y'] = res[1]

# PPI = diagonal en píxeles / diagonal en pulgadas
df['PPI'] = np.sqrt(df['Res_X']**2 + df['Res_Y']**2) / df['Inches']

print(df[['ScreenResolution', 'Touchscreen', 'IPS', 'Res_X', 'Res_Y', 'PPI']].
      ↪head())
```

	ScreenResolution	Touchscreen	IPS	Res_X	Res_Y	\
0	IPS Panel Retina Display 2560x1600	0	1	2560	1600	
1	1440x900	0	0	1440	900	
2	Full HD 1920x1080	0	0	1920	1080	
3	IPS Panel Retina Display 2880x1800	0	1	2880	1800	
4	IPS Panel Retina Display 2560x1600	0	1	2560	1600	

	PPI
0	226.983005
1	127.677940
2	141.211998
3	220.534624
4	226.983005

3.4.3 1.4.3 Memory

Esta es la más enredada. Tiene tres problemas al tiempo:

1. Unas capacidades están en GB y otras en TB
2. Hay varios tipos de disco: SSD, HDD, Flash Storage e Hybrid
3. Algunos equipos traen dos discos, separados con un +

Lo que hicimos fue pasar todo a GB y crear una columna por cada tipo de disco. Así un portátil con SSD de 128GB y disco duro de 1TB queda bien representado, con su capacidad en la columna que le corresponde.

```
[5]: import re

def a_gigas(texto):
    """Saca la capacidad en GB de un texto tipo '128GB SSD' o '1.0TB HDD'."""
    m = re.search(r'([\d\.]+)\s*(TB|GB)', texto)
    if not m:
        return 0.0
    valor = float(m.group(1))
    if m.group(2) == 'TB':
        valor = valor * 1000    # 1TB = 1000GB
    return valor

# separamos los equipos que traen dos discos
partes = df['Memory'].str.split('+', n=1, expand=True)
if partes.shape[1] == 1:
    partes[1] = None

disco1 = partes[0].fillna('').str.strip()
disco2 = partes[1].fillna('').str.strip()

cap1 = disco1.apply(a_gigas)
cap2 = disco2.apply(a_gigas)

# cada capacidad va a la columna del tipo de disco que le corresponde
for tipo in ['SSD', 'HDD', 'Flash Storage', 'Hybrid']:
    col = tipo.replace(' ', '_') + '_GB'
    df[col] = cap1 * disco1.str.contains(tipo) + cap2 * disco2.str.
    ↪contains(tipo)

print(df[['Memory', 'SSD_GB', 'HDD_GB', 'Flash_Storage_GB', 'Hybrid_GB']].
    ↪head(10))
```

	Memory	SSD_GB	HDD_GB	Flash_Storage_GB	Hybrid_GB
0	128GB SSD	128.0	0.0	0.0	0.0
1	128GB Flash Storage	0.0	0.0	128.0	0.0
2	256GB SSD	256.0	0.0	0.0	0.0
3	512GB SSD	512.0	0.0	0.0	0.0
4	256GB SSD	256.0	0.0	0.0	0.0
5	500GB HDD	0.0	500.0	0.0	0.0
6	256GB Flash Storage	0.0	0.0	256.0	0.0

7	256GB Flash Storage	0.0	0.0	256.0	0.0
8	512GB SSD	512.0	0.0	0.0	0.0
9	256GB SSD	256.0	0.0	0.0	0.0

```
[6]: # revisamos que no se nos haya escapado ningún caso raro
total = df[['SSD_GB', 'HDD_GB', 'Flash_Storage_GB', 'Hybrid_GB']].sum(axis=1)
print("Equipos que quedaron en 0 de almacenamiento:", (total == 0).sum())

print("\nCuántos equipos tienen cada tipo de disco:")
print((df[['SSD_GB', 'HDD_GB', 'Flash_Storage_GB', 'Hybrid_GB']] > 0).sum())
```

Equipos que quedaron en 0 de almacenamiento: 0

Cuántos equipos tienen cada tipo de disco:

SSD_GB	843
HDD_GB	576
Flash_Storage_GB	75
Hybrid_GB	12

dtype: int64

3.4.4 1.4.4 Cpu y Gpu

Cpu trae el modelo completo del procesador, tan específico que hay modelos que aparecen una sola vez en todo el dataset. Eso no sirve para agrupar. Nos quedamos con la gama (Intel Core i5, Intel Core i7, etc.) y de la tarjeta gráfica solo con la marca.

Después de extraer la gama quedaban 40 categorías distintas, y 14 de ellas tenían un solo equipo. Con tan pocos casos no aportan nada y solo ensucian el análisis, así que agrupamos en “Otro” las que tienen menos de 10 equipos. Quedamos con 8 categorías y solo 79 equipos (6%) caen en “Otro”.

```
[7]: df['Cpu_gama'] = df['Cpu'].str.split().str[:3].str.join(' ')
df['Gpu_marca'] = df['Gpu'].str.split().str[0]

print("Categorías de CPU antes de agrupar:", df['Cpu_gama'].nunique())

# hay 40 gamas distintas y muchas aparecen en 1 o 2 equipos,
# así que juntamos en "Otro" las que tengan menos de 10
conteo = df['Cpu_gama'].value_counts()
frecuentes = conteo[conteo >= 10].index
df['Cpu_gama'] = df['Cpu_gama'].where(df['Cpu_gama'].isin(frecuentes), 'Otro')

print("Después de agrupar:", df['Cpu_gama'].nunique())
print()
print(df['Cpu_gama'].value_counts())
print("\nMarcas de tarjeta gráfica:")
print(df['Gpu_marca'].value_counts())
```

Categorías de CPU antes de agrupar: 40

Después de agrupar: 8

```
Cpu_gama
Intel Core i7      527
Intel Core i5      423
Intel Core i3      136
Intel Celeron Dual  80
Otro               79
Intel Pentium Quad  27
Intel Core M       19
AMD A9-Series 9420 12
Name: count, dtype: int64
```

Marcas de tarjeta gráfica:

```
Gpu_marca
Intel      722
Nvidia     400
AMD        180
ARM         1
Name: count, dtype: int64
```

3.4.5 1.4.5 OpSys

Hay nueve sistemas operativos distintos, pero varios tienen dos o tres equipos nomás (Android, Chrome OS, Windows 10 S). Con tan pocos casos no se puede concluir nada, así que los agrupamos en cuatro.

```
[8]: print("Antes:")
      print(df['OpSys'].value_counts())

      def agrupar_so(x):
          if x in ['Windows 10', 'Windows 7', 'Windows 10 S']:
              return 'Windows'
          elif x in ['macOS', 'Mac OS X']:
              return 'Mac'
          elif x == 'Linux':
              return 'Linux'
          else:
              return 'Otro'

      df['SO'] = df['OpSys'].apply(agrupar_so)

      print("\nDespués:")
      print(df['SO'].value_counts())
```

```
Antes:
OpSys
Windows 10      1072
No OS           66
```



```
Linux          62
Windows 7      45
Chrome OS      27
macOS          13
Mac OS X       8
Windows 10 S   8
Android        2
Name: count, dtype: int64
```

Después:

```
S0
Windows      1125
Otro         95
Linux        62
Mac          21
Name: count, dtype: int64
```

3.5 1.5 Armamos el dataset limpio

Nos quedamos con las columnas nuevas y botamos las originales que ya procesamos. También quitamos laptop_ID, que es solo un consecutivo y no aporta nada.

```
[9]: columnas = [
    'Company', 'TypeName', 'Inches', 'Ram_GB', 'Weight_kg',
    'Touchscreen', 'IPS', 'Res_X', 'Res_Y', 'PPI',
    'SSD_GB', 'HDD_GB', 'Flash_Storage_GB', 'Hybrid_GB',
    'Cpu_gama', 'Gpu_marca', 'S0', 'Price_euros'
]

df_limpio = df[columnas].copy()

print("Tamaño final:", df_limpio.shape)
print("\n--- Tipos de dato ---")
print(df_limpio.dtypes)
print("\nNulos:", df_limpio.isnull().sum().sum())
df_limpio.head()
```

Tamaño final: (1303, 18)

--- Tipos de dato ---

```
Company          object
TypeName         object
Inches           float64
Ram_GB           int64
Weight_kg        float64
Touchscreen      int64
IPS              int64
Res_X            int64
```

```

Res_Y          int64
PPI            float64
SSD_GB         float64
HDD_GB         float64
Flash_Storage_GB float64
Hybrid_GB      float64
Cpu_gama       object
Gpu_marca      object
S0             object
Price_euros    float64
dtype: object

```

Nulos: 0

```

[9]: Company  TypeName  Inches  Ram_GB  Weight_kg  Touchscreen  IPS  Res_X  \
0   Apple  Ultrabook   13.3     8      1.37         0     1   2560
1   Apple  Ultrabook   13.3     8      1.34         0     0   1440
2    HP    Notebook   15.6     8      1.86         0     0   1920
3   Apple  Ultrabook   15.4    16      1.83         0     1   2880
4   Apple  Ultrabook   13.3     8      1.37         0     1   2560

```

```

      Res_Y      PPI  SSD_GB  HDD_GB  Flash_Storage_GB  Hybrid_GB  \
0   1600  226.983005   128.0    0.0             0.0         0.0
1    900  127.677940    0.0    0.0             128.0         0.0
2   1080  141.211998   256.0    0.0             0.0         0.0
3   1800  220.534624   512.0    0.0             0.0         0.0
4   1600  226.983005   256.0    0.0             0.0         0.0

```

```

      Cpu_gama  Gpu_marca    S0  Price_euros
0  Intel Core i5    Intel  Mac    1339.69
1  Intel Core i5    Intel  Mac     898.94
2  Intel Core i5    Intel  Otro    575.00
3  Intel Core i7     AMD   Mac    2537.45
4  Intel Core i5    Intel  Mac    1803.60

```

3.6 1.6 Un primer vistazo

Antes de pasarle esto al análisis estadístico, miramos rápido cómo se ven los datos.

```
[10]: print(df_limpio.describe().T)
```

```

      count      mean      std      min      25%  \
Inches    1303.0   15.017191  1.426304  10.100000  14.000000
Ram_GB     1303.0    8.382195  5.084665   2.000000   4.000000
Weight_kg   1303.0    2.038734  0.665475   0.690000   1.500000
Touchscreen 1303.0    0.147352  0.354593   0.000000   0.000000
IPS         1303.0    0.280123  0.449231   0.000000   0.000000
Res_X       1303.0  1894.784344  494.641028  1366.000000  1600.000000

```

Res_Y	1303.0	1070.830391	284.519410	768.000000	900.000000
PPI	1303.0	146.635987	43.121345	90.583402	127.335675
SSD_GB	1303.0	183.732924	186.966903	0.000000	0.000000
HDD_GB	1303.0	413.783576	515.818779	0.000000	0.000000
Flash_Storage_GB	1303.0	4.555641	30.274090	0.000000	0.000000
Hybrid_GB	1303.0	8.831926	92.567185	0.000000	0.000000
Price_euros	1303.0	1123.686992	699.009043	174.000000	599.000000


	50%	75%	max
Inches	15.600000	15.600000	18.400000
Ram_GB	8.000000	8.000000	64.000000
Weight_kg	2.040000	2.300000	4.700000
Touchscreen	0.000000	0.000000	1.000000
IPS	0.000000	1.000000	1.000000
Res_X	1920.000000	1920.000000	3840.000000
Res_Y	1080.000000	1080.000000	2160.000000
PPI	141.211998	157.350512	352.465147
SSD_GB	256.000000	256.000000	1024.000000
HDD_GB	0.000000	1000.000000	2000.000000
Flash_Storage_GB	0.000000	0.000000	512.000000
Hybrid_GB	0.000000	0.000000	1000.000000
Price_euros	977.000000	1487.880000	6099.000000

```
[11]: fig, axes = plt.subplots(1, 2, figsize=(13, 4))

sns.histplot(df_limpio['Price_euros'], bins=40, kde=True, ax=axes[0],
             color='#6B21A8')
axes[0].set_title('Distribución del precio')
axes[0].set_xlabel('Precio (euros)')
axes[0].set_ylabel('Frecuencia')

orden = df_limpio['Company'].value_counts().index
sns.countplot(y='Company', data=df_limpio, order=orden, ax=axes[1],
             color='#0D9488')
axes[1].set_title('Equipos por marca')
axes[1].set_xlabel('Cantidad')
axes[1].set_ylabel('')

plt.tight_layout()
plt.show()
```



Se nota que el precio está sesgado hacia la derecha: la mayoría de equipos son de gama media y hay unos pocos muy caros que estiran la cola. Esto hay que tenerlo en cuenta en la Etapa 2, porque cuando la distribución es así la mediana representa mejor el valor típico que el promedio.

3.7 1.7 Guardamos el archivo limpio

Este CSV es con el que van a trabajar las etapas 2 y 3.

```
[12]: df_limpio.to_csv('laptop_price_limpio.csv', index=False)
      print("Listo:", len(df_limpio), "filas y", df_limpio.shape[1], "columnas")
```

Listo: 1303 filas y 18 columnas

3.8 Resumen de lo que hicimos

Empezamos con 13 columnas, de las cuales 10 eran texto sin procesar, y terminamos con 18 columnas utilizables. No perdimos ningún registro, los 1.303 equipos siguen ahí.

Lo que se hizo en cada columna:

- **Ram, Weight:** quitamos la unidad y las volvimos números
- **ScreenResolution:** la partimos en 5 columnas (IPS, táctil, ancho, alto, PPI)
- **Memory:** normalizamos las unidades y la separamos por tipo de disco
- **Cpu, Gpu:** nos quedamos con la gama y la marca
- **OpSys:** agrupamos de 9 categorías a 4

4 ETAPA 2 — Análisis estadístico

A cargo de: Jhonatan Stiben Rey Velasquez

Con los datos ya depurados, entendemos cómo se comportan antes de meterles cualquier modelo: qué valores son típicos, qué tanto varían, qué forma tienen las distribuciones, si hay valores raros y qué variables parecen tener relación con el precio.

4.1 2.1 Retomamos el conjunto depurado

Como este cuaderno integra las tres etapas, no volvemos a leer el CSV: seguimos con el `df_limpio` que quedó de la Etapa 1.

```
[13]: df = df_limpio.copy()

print("Dimensiones:", df.shape)
print("Nulos:", df.isnull().sum().sum())
df.head()
```

Dimensiones: (1303, 18)

Nulos: 0

```
[13]: Company   TypeName  Inches  Ram_GB  Weight_kg  Touchscreen  IPS  Res_X  \
0   Apple  Ultrabook   13.3      8      1.37           0    1   2560
1   Apple  Ultrabook   13.3      8      1.34           0    0   1440
2    HP    Notebook   15.6      8      1.86           0    0   1920
3   Apple  Ultrabook   15.4     16      1.83           0    1   2880
4   Apple  Ultrabook   13.3      8      1.37           0    1   2560

      Res_Y      PPI  SSD_GB  HDD_GB  Flash_Storage_GB  Hybrid_GB  \
0    1600  226.983005   128.0    0.0              0.0        0.0
1     900  127.677940    0.0    0.0             128.0        0.0
2    1080  141.211998   256.0    0.0              0.0        0.0
3    1800  220.534624   512.0    0.0              0.0        0.0
4    1600  226.983005   256.0    0.0              0.0        0.0

      Cpu_gama  Gpu_marca   SO  Price_euros
0  Intel Core i5    Intel  Mac    1339.69
1  Intel Core i5    Intel  Mac     898.94
2  Intel Core i5    Intel  Otro    575.00
3  Intel Core i7     AMD   Mac    2537.45
4  Intel Core i5    Intel  Mac    1803.60
```

```
[14]: # separamos las numéricas que vamos a analizar
numericas = ['Price_euros', 'Ram_GB', 'Weight_kg', 'Inches', 'PPI', 'SSD_GB', 'HDD_GB']
df[numericas].head()
```

```
[14]: Price_euros  Ram_GB  Weight_kg  Inches  PPI  SSD_GB  HDD_GB
0    1339.69      8      1.37    13.3  226.983005  128.0    0.0
1     898.94      8      1.34    13.3  127.677940   0.0    0.0
2     575.00      8      1.86    15.6  141.211998  256.0    0.0
3    2537.45     16      1.83    15.4  220.534624  512.0    0.0
4    1803.60      8      1.37    13.3  226.983005  256.0    0.0
```

4.2 2.2 Medidas de tendencia central

Calculamos media, mediana y moda para cada variable numérica. Comparar las tres sirve para darse una idea de si la distribución está balanceada o no: cuando la media se aleja mucho de la mediana es porque hay valores extremos jalando el promedio.

```
[15]: tendencia = pd.DataFrame({
    'Media': df[numericas].mean(),
    'Mediana': df[numericas].median(),
    'Moda': df[numericas].mode().iloc[0]
})

# diferencia porcentual entre media y mediana
# (si la mediana es 0 no se puede calcular, lo dejamos vacío)
tendencia['Dif. media-mediana (%)'] = np.where(
    tendencia['Mediana'] != 0,
    (tendencia['Media'] - tendencia['Mediana']) / tendencia['Mediana'] * 100,
    np.nan)

print(tendencia.round(2))
```

	Media	Mediana	Moda	Dif. media-mediana (%)
Price_euros	1123.69	977.00	1099.00	15.01
Ram_GB	8.38	8.00	8.00	4.78
Weight_kg	2.04	2.04	2.20	-0.06
Inches	15.02	15.60	15.60	-3.74
PPI	146.64	141.21	141.21	3.84
SSD_GB	183.73	256.00	256.00	-28.23
HDD_GB	413.78	0.00	0.00	NaN

4.2.1 Qué nos dice esto

En el precio la media queda en unos 1.124 euros pero la mediana en 977. O sea que el promedio está por encima de lo que realmente paga la mayoría, porque hay unos portátiles muy caros que lo jalen hacia arriba. **Para hablar del precio típico es mejor usar la mediana.**

El caso más llamativo es HDD_GB: la media da 414 GB pero la mediana da 0. Eso pasa porque más de la mitad de los equipos no traen disco duro mecánico, solo SSD. Cuando la mayoría de los valores son cero, el promedio deja de significar algo útil.

En Inches y Weight_kg en cambio la media y la mediana son casi iguales, así que esas sí están repartidas de forma más pareja.

4.3 2.3 Medidas de dispersión

Ahora miramos qué tanto se separan los datos. Además del rango, la varianza y la desviación estándar, agregamos el **coeficiente de variación**, que es la desviación dividida entre la media. Sirve para comparar variables que están en unidades distintas: no se puede comparar directo una desviación en euros contra una en kilos.

```
[16]: dispersion = pd.DataFrame({
    'Mínimo': df[numéricas].min(),
    'Máximo': df[numéricas].max(),
    'Rango': df[numéricas].max() - df[numéricas].min(),
    'Varianza': df[numéricas].var(),
    'Desv. estándar': df[numéricas].std()
})

dispersion['Coef. variación'] = df[numéricas].std() / df[numéricas].mean()

print(dispersion.round(2))
```

	Mínimo	Máximo	Rango	Varianza	Desv. estándar \
Price_euros	174.00	6099.00	5925.00	488613.64	699.01
Ram_GB	2.00	64.00	62.00	25.85	5.08
Weight_kg	0.69	4.70	4.01	0.44	0.67
Inches	10.10	18.40	8.30	2.03	1.43
PPI	90.58	352.47	261.88	1859.45	43.12
SSD_GB	0.00	1024.00	1024.00	34956.62	186.97
HDD_GB	0.00	2000.00	2000.00	266069.01	515.82

	Coef. variación
Price_euros	0.62
Ram_GB	0.61
Weight_kg	0.33
Inches	0.09
PPI	0.29
SSD_GB	1.02
HDD_GB	1.25

4.3.1 Qué nos dice esto

El coeficiente de variación deja ver cuáles variables son más dispersas en términos relativos. `HDD_GB` y `SSD_GB` son las más variables (más de 1), que tiene sentido porque hay equipos sin ninguno de los dos y otros con 1 o 2 TB.

En el otro extremo, `Inches` tiene un coeficiente de apenas 0.09: casi todos los portátiles miden entre 14 y 15.6 pulgadas. Es una variable bastante uniforme, lo cual adelanta algo — si casi no varía, difícilmente va a servir para explicar diferencias de precio.

4.4 2.4 Forma de las distribuciones

La asimetría (skewness) dice hacia dónde está estirada la distribución y la curtosis qué tan pesadas son las colas.

Para leerlas: - Asimetría cerca de 0 es simétrica; positiva es estirada a la derecha; negativa a la izquierda - Curtosis alta significa que hay más valores extremos de lo normal

```
[17]: forma = pd.DataFrame({
    'Asimetría': df[numéricas].skew(),
    'Curtosis': df[numéricas].kurtosis()
})

def interpretar(s):
    if s > 1: return 'Muy sesgada a la derecha'
    elif s > 0.5: return 'Sesgada a la derecha'
    elif s > -0.5: return 'Aproximadamente simétrica'
    elif s > -1: return 'Sesgada a la izquierda'
    else: return 'Muy sesgada a la izquierda'


forma['Interpretación'] = forma['Asimetría'].apply(interpretar)
print(forma.round(2))
```

	Asimetría	Curtosis	Interpretación
Price_euros	1.52	4.37	Muy sesgada a la derecha
Ram_GB	2.69	15.34	Muy sesgada a la derecha
Weight_kg	1.14	2.46	Muy sesgada a la derecha
Inches	-0.45	-0.07	Aproximadamente simétrica
PPI	2.02	5.08	Muy sesgada a la derecha
SSD_GB	1.37	3.22	Muy sesgada a la derecha
HDD_GB	0.89	-0.04	Sesgada a la derecha

```
[18]: fig, axes = plt.subplots(1, 3, figsize=(15, 4))

for ax, col in zip(axes, ['Price_euros', 'Ram_GB', 'Inches']):
    sns.histplot(df[col], kde=True, ax=ax, color='#6B21A8')
    ax.axvline(df[col].mean(), color='red', linestyle='--', label='Media')
    ax.axvline(df[col].median(), color='green', linestyle='--', label='Mediana')
    ax.set_title(f'{col} (asimetría = {df[col].skew():.2f})')
    ax.legend()

plt.tight_layout()
plt.show()
```



4.4.1 Qué nos dice esto

Casi todas las variables están sesgadas a la derecha. El precio tiene asimetría de 1.52 y la RAM de 2.69, que es bastante alta. En los gráficos se ve clarito: la línea roja (media) queda a la derecha de la verde (mediana) en el precio y en la RAM, mientras que en las pulgadas están casi encima una de otra.

Inches es la única con asimetría negativa (-0.45), o sea ligeramente estirada hacia la izquierda, aunque bastante cerca de ser simétrica.

La RAM también tiene una curtosis de 15.3, que es altísima. Eso significa que hay muchos valores concentrados en el centro (casi todos los equipos son de 4 u 8 GB) y unos pocos muy alejados (los de 32 y 64 GB).

4.5 2.5 Detección de valores atípicos

Para encontrar los outliers usamos el método del rango intercuartílico. La idea es calcular el primer y el tercer cuartil, sacar la diferencia (el IQR), y considerar atípico todo lo que quede más allá de 1.5 veces el IQR por debajo de Q1 o por encima de Q3.

Es el mismo criterio que usan los diagramas de caja para dibujar los bigotes.

```
[19]: def detectar_outliers(serie):
    q1 = serie.quantile(0.25)
    q3 = serie.quantile(0.75)
    iqr = q3 - q1
    limite_inf = q1 - 1.5 * iqr
    limite_sup = q3 + 1.5 * iqr
    atipicos = ((serie < limite_inf) | (serie > limite_sup)).sum()
    return pd.Series({
        'Q1': q1, 'Q3': q3, 'IQR': iqr,
        'Límite inf.': limite_inf, 'Límite sup.': limite_sup,
        'N° atípicos': atipicos,
        '% del total': atipicos / len(serie) * 100
    })

outliers = df[numéricas].apply(detectar_outliers).T
print(outliers.round(2))
```

	Q1	Q3	IQR	Límite inf.	Límite sup.	N° atípicos \
Price_euros	599.00	1487.88	888.88	-734.32	2821.20	29.0
Ram_GB	4.00	8.00	4.00	-2.00	14.00	221.0
Weight_kg	1.50	2.30	0.80	0.30	3.50	46.0
Inches	14.00	15.60	1.60	11.60	18.00	39.0
PPI	127.34	157.35	30.01	82.31	202.37	116.0
SSD_GB	0.00	256.00	256.00	-384.00	640.00	18.0
HDD_GB	0.00	1000.00	1000.00	-1500.00	2500.00	0.0


	% del total
Price_euros	2.23

Ram_GB	16.96
Weight_kg	3.53
Inches	2.99
PPI	8.90
SSD_GB	1.38
HDD_GB	0.00

```
[20]: fig, axes = plt.subplots(1, 3, figsize=(15, 4))

for ax, col in zip(axes, ['Price_euros', 'Ram_GB', 'Weight_kg']):
    sns.boxplot(y=df[col], ax=ax, color='#0D9488')
    ax.set_title(f'{col}')

plt.tight_layout()
plt.show()
```



```
[21]: # miramos qué equipos son los que el método marca como atípicos en RAM
atipicos_ram = df[df['Ram_GB'] > outliers.loc['Ram_GB', 'Límite sup.']]

print("Equipos marcados como atípicos por RAM:", len(atipicos_ram))
print("\nCómo se reparten por tipo de equipo:")
print(atipicos_ram['TypeName'].value_counts())
print("\nRAM de esos equipos:")
print(atipicos_ram['Ram_GB'].value_counts().sort_index())
```

Equipos marcados como atípicos por RAM: 221

Cómo se reparten por tipo de equipo:

TypeName	
Gaming	116
Ultrabook	38
Notebook	34
2 in 1 Convertible	23
Workstation	9
Netbook	1
Name: count, dtype: int64	

RAM de esos equipos:

```
Ram_GB
16      200
24        3
32       17
64        1
Name: count, dtype: int64
```

4.5.1 Qué nos dice esto

Acá aparece algo que vale la pena aclarar. El método marca **221 equipos como atípicos por RAM**, que es el 17% del dataset. Es un montón.

Pero al revisar cuáles son, resulta que son equipos de 12, 16, 24, 32 y 64 GB, y en su mayoría son Gaming y Workstation. **No son errores, son equipos de gama alta reales.**

Lo que pasa es que como la gran mayoría del catálogo son portátiles de 4 y 8 GB, el rango intercuartílico queda muy angosto ($Q1=4$, $Q3=8$, $IQR=4$) y cualquier cosa por encima de 14 GB cae fuera del límite. El método está funcionando bien, pero un valor atípico en el sentido estadístico no siempre es un dato malo.

Por eso no los eliminamos. Si los quitáramos estaríamos borrando justo los equipos más potentes, que son los que explican los precios altos. Los dejamos y lo dejamos anotado, que es distinto a ignorarlos.

En el precio en cambio los atípicos son solo 29 (2.2%) y corresponden a portátiles de más de 2.800 euros, que también son reales.

4.6 2.6 Comparación entre variables

Ahora miramos qué relación tiene cada variable con el precio, que es lo que al final queremos entender.

Empezamos con las numéricas usando correlación.


```
[22]: correlaciones = df[numéricas].corr()['Price_euros'].drop('Price_euros')
      correlaciones = correlaciones.sort_values(ascending=False)

      print("Correlación de cada variable con el precio:")
      print(correlaciones.round(3))
```

Correlación de cada variable con el precio:

```
Ram_GB      0.743
SSD_GB      0.671
PPI          0.473
Weight_kg    0.210
Inches       0.068
HDD_GB      -0.096
Name: Price_euros, dtype: float64
```

```
[23]: plt.figure(figsize=(9, 6))
sns.heatmap(df[numericas].corr(), annot=True, fmt='.2f', cmap='RdYlGn',
            center=0)
plt.title('Correlación entre variables numéricas')
plt.tight_layout()
plt.show()
```



4.6.1 Qué nos dice esto

La RAM es la que más se relaciona con el precio (0.74), seguida del SSD (0.67) y del PPI (0.47). Tiene sentido: más memoria, más disco sólido y mejor pantalla salen más caro.

Dos cosas curiosas:

Las pulgadas casi no se relacionan con el precio (0.07). Uno pensaría que un portátil más grande cuesta más, pero no: hay equipos de 15.6 pulgadas baratísimos y ultrabooks de 13 pulgadas carísimos. El tamaño solo no dice nada de la gama.

El disco duro tiene correlación negativa (-0.10). O sea que a más disco duro, un poco menos de precio. Suena raro pero se explica: los equipos con HDD son en general los de gama baja, mientras que los caros vienen con SSD. No es que el disco duro abarate el equipo, es que va de la mano con equipos económicos.

Ahora comparamos el precio entre las variables categóricas.

```
[24]: for columna in ['TypeName', 'SO', 'Cpu_gama', 'Gpu_marca']:
        resumen = df.groupby(columna)['Price_euros'].agg(['count', 'mean', 'median', 'std'])
        resumen = resumen.sort_values('median', ascending=False)
        print(f"--- Precio según {columna} ---")
        print(resumen.round(0))
        print()
```

--- Precio según TypeName ---

	count	mean	median	std
TypeName				
Workstation	29	2280.0	2065.0	713.0
Ultrabook	196	1548.0	1499.0	489.0
Gaming	205	1731.0	1493.0	814.0
2 in 1 Convertible	121	1282.0	1199.0	613.0
Notebook	727	782.0	691.0	444.0
Netbook	25	636.0	340.0	581.0

--- Precio según SO ---

	count	mean	median	std
SO				
Mac	21	1564.0	1340.0	562.0
Windows	1125	1190.0	1049.0	707.0
Linux	62	617.0	579.0	253.0
Otro	95	575.0	479.0	339.0

--- Precio según Cpu_gama ---

	count	mean	median	std
Cpu_gama				
Intel Core i7	527	1596.0	1476.0	704.0
Intel Core M	19	1324.0	1262.0	612.0
Intel Core i5	423	1015.0	955.0	376.0
Intel Core i3	136	542.0	499.0	143.0
Otro	79	675.0	469.0	794.0
AMD A9-Series 9420	12	446.0	438.0	46.0
Intel Pentium Quad	27	421.0	389.0	117.0
Intel Celeron Dual	80	312.0	298.0	75.0

--- Precio según Gpu_marca ---


	count	mean	median	std
Gpu_marca				
Nvidia	400	1490.0	1239.0	817.0
Intel	722	1008.0	900.0	590.0
AMD	180	776.0	676.0	434.0
ARM	1	659.0	659.0	NaN

```
[25]: fig, axes = plt.subplots(1, 2, figsize=(15, 5))

orden_tipo = df.groupby('TypeName')['Price_euros'].median().
    ↪sort_values(ascending=False).index
sns.boxplot(x='Price_euros', y='TypeName', data=df, order=orden_tipo,
    ↪ax=axes[0], color='#6B21A8')
axes[0].set_title('Precio según tipo de equipo')

orden_cpu = df.groupby('Cpu_gama')['Price_euros'].median().
    ↪sort_values(ascending=False).index
sns.boxplot(x='Price_euros', y='Cpu_gama', data=df, order=orden_cpu,
    ↪ax=axes[1], color='#0D9488')
axes[1].set_title('Precio según gama de procesador')

plt.tight_layout()
plt.show()
```



```
[26]: # las dos variables binarias
for columna in ['Touchscreen', 'IPS']:
    resumen = df.groupby(columna)['Price_euros'].agg(['count', 'mean',
    ↪'median'])
    diferencia = resumen.loc[1, 'median'] - resumen.loc[0, 'median']
    print(f"--- {columna} ---")
    print(resumen.round(0))
    print(f"Diferencia en la mediana: {diferencia:.0f} euros")
    print()
```

```
--- Touchscreen ---
      count    mean  median
Touchscreen
0         1111  1068.0   919.0
1         192   1445.0  1399.0
Diferencia en la mediana: 480 euros
```

```

--- IPS ---
      count    mean  median
IPS
0         938  1014.0   848.0
1         365  1406.0  1260.0
Diferencia en la mediana: 412 euros

```

4.6.2 Qué nos dice esto

Por tipo de equipo hay diferencias grandes. Las Workstation tienen una mediana de 2.065 euros y los Netbook de 340. Los Notebook, que son la mayoría del catálogo (727 de 1.303), están en 691, o sea que son la gama de entrada.

Por procesador el orden es el que uno esperaría: i7 arriba (mediana 1.476), después i5 (955), i3 (499) y los Celeron abajo (298). La progresión es bien clara.

Por sistema operativo los Mac son los más caros, pero hay que tener cuidado con esa conclusión: son solo 21 equipos de 1.303. Con tan pocos casos el dato no es muy confiable. Los Windows, con 1.125 equipos, sí son representativos.

Las binarias también muestran diferencia. Los equipos con pantalla táctil tienen una mediana 480 euros más alta, y los que tienen panel IPS 412 euros más. Aunque acá vale la pena aclarar que probablemente no es la pantalla en sí la que sube el precio, sino que ese tipo de pantallas vienen en equipos de gama alta que ya son caros por otras razones.

4.7 2.7 Hipótesis para la siguiente etapa

De todo lo anterior salen algunas ideas que la Etapa 3 puede probar con el modelo:

1. **La RAM y el SSD son los que más pesan en el precio.** Son las dos correlaciones más altas (0.74 y 0.67), así que deberían ser las variables más importantes del modelo.
2. **El tamaño de pantalla no sirve para predecir el precio,** pero el PPI sí (0.47). Lo que importa no es qué tan grande es la pantalla sino qué tan buena.
3. **El tipo de equipo y la gama del procesador son buenos separadores.** Las medianas entre categorías son muy distintas, o sea que agrupan bien.
4. **Cuidado con el disco duro.** Su correlación negativa no significa que abarate el equipo, sino que viene en equipos de gama baja. Meterlo al modelo sin entender esto puede llevar a interpretaciones equivocadas.
5. **La distribución del precio está sesgada.** Eso puede afectar a un modelo de regresión lineal, que asume cierta simetría en los errores. Podría valer la pena revisarlo.

4.8 Resumen de la Etapa 2

Lo que hicimos:

- Calculamos media, mediana y moda, y vimos que en el precio la mediana representa mejor el valor típico porque la distribución está sesgada

- Medimos la dispersión con rango, varianza, desviación estándar y coeficiente de variación, que permite comparar variables con unidades distintas
- Analizamos la forma con asimetría y curtosis: casi todas las variables están estiradas hacia la derecha
- Detectamos outliers con el método del rango intercuartílico y decidimos conservarlos después de revisar que son equipos de gama alta reales, no errores
- Comparamos el precio contra todas las variables, numéricas y categóricas, y dejamos cinco hipótesis planteadas para el modelo

5 ETAPA 3 — Visualización, modelo predictivo y storytelling

A cargo de: Andres Sebastian Quintana Morales

Contamos la historia que salió de los datos, armamos un modelo que predice el precio de un portátil a partir de sus características, y planteamos para qué sirve en la práctica.

5.1 3.1 Librerías del modelo

Las de análisis ya están cargadas desde la Etapa 1; acá solo agregamos las de scikit-learn.

```
[27]: from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error

print("Listo. Trabajamos con", df.shape[0], "equipos y", df.shape[1],
      ↪ "variables.")
```

Listo. Trabajamos con 1303 equipos y 18 variables.

6 PARTE 1: La historia que cuentan los datos

6.1 3.2 El punto de partida

La pregunta era: ¿qué hace que un portátil sea caro?

La respuesta intuitiva sería el tamaño o la marca. Pero los datos dicen otra cosa.


```
[28]: fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# lo que uno pensaría que importa
sns.scatterplot(x='Inches', y='Price_euros', data=df, alpha=0.4, ax=axes[0],
               ↪ color='#999999')
axes[0].set_title(f'Tamaño de pantalla vs precio (correlación = {df.Inches.
               ↪ corr(df.Price_euros):.2f})')
axes[0].set_xlabel('Pulgadas')
axes[0].set_ylabel('Precio (euros)')
```



```
# lo que realmente importa
sns.scatterplot(x='Ram_GB', y='Price_euros', data=df, alpha=0.4, ax=axes[1],
               color='#6B21A8')
axes[1].set_title(f'Memoria RAM vs precio (correlación = {df.Ram_GB.corr(df.
               Price_euros):.2f})')
axes[1].set_xlabel('RAM (GB)')
axes[1].set_ylabel('Precio (euros)')

plt.tight_layout()
plt.show()
```



El tamaño no dice nada. La nube de puntos de la izquierda está completamente dispersa: hay portátiles de 15.6 pulgadas que cuestan 300 euros y otros del mismo tamaño que cuestan 4.000. La correlación es de apenas 0.07.

La RAM sí. A la derecha se ve una tendencia clara hacia arriba. La correlación es de 0.74, la más alta de todo el dataset.

Esto tiene sentido si uno lo piensa: el tamaño de la pantalla es una decisión de formato, no de potencia. Un portátil grande puede ser barato porque es pesado y básico.

6.2 3.3 Lo que de verdad mueve el precio


```
[29]: numericas = ['Ram_GB', 'SSD_GB', 'PPI', 'Weight_kg', 'Inches', 'HDD_GB']
corr = df[numericas + ['Price_euros']].corr()['Price_euros'].
      drop('Price_euros').sort_values()

plt.figure(figsize=(9, 5))
colores = ['#DC2626' if v < 0 else '#0D9488' for v in corr.values]
plt.barh(corr.index, corr.values, color=colores)
plt.axvline(0, color='black', linewidth=0.8)
plt.title('Qué tanto se relaciona cada característica con el precio')
plt.xlabel('Correlación con el precio')
```

```

for i, v in enumerate(corr.values):
    plt.text(v + (0.02 if v > 0 else -0.08), i, f'{v:.2f}', va='center')
plt.tight_layout()
plt.show()

```



Hay un dato que llama la atención: **el disco duro tiene correlación negativa**.

No es que un disco duro haga más barato al equipo. Es que los portátiles que todavía traen HDD son los de gama de entrada, mientras que los caros vienen con SSD. La variable está señalando el segmento, no causando el precio.

Es un buen recordatorio de que correlación no es causalidad.

6.3 3.4 Las gamas del mercado

Al agrupar por tipo de equipo aparece una segmentación bastante clara.

```


[30]: fig, axes = plt.subplots(1, 2, figsize=(15, 5))

orden = df.groupby('TypeName')['Price_euros'].median().
    ↪sort_values(ascending=False).index
sns.boxplot(x='Price_euros', y='TypeName', data=df, order=orden, ax=axes[0],
    ↪color='#6B21A8')
axes[0].set_title('Precio por tipo de equipo')
axes[0].set_xlabel('Precio (euros)')
axes[0].set_ylabel('')

```

```
orden_cpu = df.groupby('Cpu_gama')['Price_euros'].median().
    ↪sort_values(ascending=False).index
sns.boxplot(x='Price_euros', y='Cpu_gama', data=df, order=orden_cpu,
    ↪ax=axes[1], color='#0D9488')
axes[1].set_title('Precio por gama de procesador')
axes[1].set_xlabel('Precio (euros)')
axes[1].set_ylabel('')

plt.tight_layout()
plt.show()
```



```
[31]: resumen = df.groupby('TypeName')['Price_euros'].agg(['count', 'median']).
    ↪sort_values('median', ascending=False)
resumen.columns = ['Equipos', 'Precio mediano']
print(resumen.round(0))
```

TypeName	Equipos	Precio mediano
Workstation	29	2065.0
Ultrabook	196	1499.0
Gaming	205	1493.0
2 in 1 Convertible	121	1199.0
Notebook	727	691.0
Netbook	25	340.0

Las Workstation tienen una mediana de 2.065 euros y los Netbook de 340: seis veces de diferencia. Y el procesador ordena el mercado casi perfecto, de i7 hacia abajo hasta los Celeron.

Es decir, **el precio no depende de una sola cosa sino de un combo de características que van juntas**. Un equipo con i7 normalmente también trae más RAM, SSD y mejor pantalla. Por eso vale la pena construir un modelo que las considere todas al tiempo, en vez de mirar variable por variable.

7 PARTE 2: El modelo predictivo

7.1 3.5 Preparar los datos para el modelo

Acá hay un problema que resolver. Scikit-learn solo trabaja con números, pero varias de nuestras variables son texto: la marca, el tipo de equipo, la gama del procesador.

No podemos simplemente asignarles números (Apple=1, Dell=2, HP=3) porque el modelo interpretaría que HP es “mayor” que Apple, lo cual no significa nada.

La solución es el **one-hot encoding**: convertir cada categoría en su propia columna de ceros y unos. Si un equipo es Ultrabook, la columna `TypeName_Ultrabook` vale 1 y todas las demás columnas de tipo valen 0.

Usamos `drop_first=True` para eliminar una categoría de cada variable y evitar información redundante: si un equipo no es ninguno de los otros tipos, ya sabemos cuál es.

```
[32]: numericas = ['Ram_GB', 'Weight_kg', 'Inches', 'PPI', 'SSD_GB', 'HDD_GB',
                'Flash_Storage_GB', 'Hybrid_GB', 'Touchscreen', 'IPS']
categoricas = ['Company', 'TypeName', 'Cpu_gama', 'Gpu_marca', 'SO']

X = pd.get_dummies(df[numericas + categoricas], columns=categoricas,
                  drop_first=True)
y = df['Price_euros']

print("Columnas antes del encoding:", len(numericas + categoricas))
print("Columnas después del encoding:", X.shape[1])
print("\nEjemplo de columnas creadas:")
print([col for col in X.columns if col.startswith('TypeName_')])
```

Columnas antes del encoding: 15

Columnas después del encoding: 46

Ejemplo de columnas creadas:

```
['TypeName_Gaming', 'TypeName_Netbook', 'TypeName_Notebook',
'Typename_Ultrabook', 'TypeName_Workstation']
```

7.2 3.6 Dividir en entrenamiento y prueba

Separamos el 80% de los datos para entrenar y guardamos el 20% para probar. Esto es importante: si evaluáramos el modelo con los mismos datos que usó para aprender, el resultado sería mentiroso. Lo que queremos saber es qué tan bien predice equipos que nunca ha visto.

El `random_state=42` es para que la división sea siempre la misma y cualquiera pueda reproducir estos resultados.

```
[33]: X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.2, random_state=42)

print("Equipos para entrenar:", len(X_train))
print("Equipos para probar: ", len(X_test))
```

Equipos para entrenar: 1042
Equipos para probar: 261

7.3 3.7 Entrenar el modelo

Usamos regresión lineal múltiple. La idea es encontrar cuánto suma o resta al precio cada característica, y sumarlo todo.

```
[34]: modelo = LinearRegression()
      modelo.fit(X_train, y_train)

      y_pred = modelo.predict(X_test)

      print("Modelo entrenado.")
      print("Intercepto:", round(modelo.intercept_, 2))
```

Modelo entrenado.
Intercepto: -231.03

7.4 3.8 ¿Qué tan bien predice?

Evaluamos con tres métricas:

- **R²**: qué porcentaje de la variación del precio logra explicar el modelo. Va de 0 a 1.
- **MAE**: en promedio, cuántos euros se equivoca.
- **RMSE**: parecido al MAE pero castiga más los errores grandes.

```
[35]: r2 = r2_score(y_test, y_pred)
      mae = mean_absolute_error(y_test, y_pred)
      rmse = np.sqrt(mean_squared_error(y_test, y_pred))

      print(f"R²    = {r2:.3f}")
      print(f"MAE    = {mae:.0f} euros")
      print(f"RMSE   = {rmse:.0f} euros")
      print()
      print(f"El modelo explica el {r2*100:.1f}% de la variación del precio.")
      print(f"En promedio se equivoca en {mae:.0f} euros sobre un precio mediano de_{y.median():.0f}.")
```

R² = 0.766
MAE = 234 euros
RMSE = 345 euros

El modelo explica el 76.6% de la variación del precio.
En promedio se equivoca en 234 euros sobre un precio mediano de 977.

```
[36]: # comparamos contra el rendimiento en entrenamiento para ver si hay sobreajuste
      print(f"R² en entrenamiento: {modelo.score(X_train, y_train):.3f}")
      print(f"R² en prueba:          {r2:.3f}")
```

R^2 en entrenamiento: 0.780

R^2 en prueba: 0.766

Los dos R^2 son parecidos (0.78 contra 0.77), o sea que el modelo **no está sobreajustado**. Si hubiera aprendido de memoria los datos de entrenamiento, el R^2 de prueba sería mucho más bajo.


Un R^2 de 0.77 significa que las características técnicas explican tres cuartas partes de la variación del precio. El cuarto restante son cosas que el dataset no captura: el prestigio de la marca, el diseño, promociones, el momento en que se tomó el precio.

```
[37]: fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# predicho vs real
axes[0].scatter(y_test, y_pred, alpha=0.4, color='#6B21A8')
lim = [0, max(y_test.max(), y_pred.max())]
axes[0].plot(lim, lim, 'r--', label='Predicción perfecta')
axes[0].set_xlabel('Precio real (euros)')
axes[0].set_ylabel('Precio predicho (euros)')
axes[0].set_title(f'Predicho vs real ( $R^2 = {r2:.3f}$ )')
axes[0].legend()

# distribución de los errores
errores = y_test - y_pred
sns.histplot(errores, bins=40, kde=True, ax=axes[1], color='#0D9488')
axes[1].axvline(0, color='red', linestyle='--')
axes[1].set_xlabel('Error (real - predicho)')
axes[1].set_ylabel('Frecuencia')
axes[1].set_title('Distribución de los errores')

plt.tight_layout()
plt.show()
```



En el gráfico de la izquierda, mientras más pegados estén los puntos a la línea roja, mejor predice. Se ve que funciona bien en el rango de 500 a 2.000 euros, donde está la mayoría del catálogo, y se dispersa en los equipos muy caros: hay pocos de esos y el modelo tuvo menos con qué aprender.

Los errores están centrados en cero, que es lo que uno quiere: el modelo no se equivoca sistemáticamente hacia arriba ni hacia abajo.


7.5 3.9 Qué aprendió el modelo

Los coeficientes dicen cuánto suma o resta cada característica al precio, manteniendo todo lo demás igual.

```
[38]: coeficientes = pd.Series(modelo.coef_, index=X.columns).sort_values()

top = pd.concat([coeficientes.head(8), coeficientes.tail(8)])

plt.figure(figsize=(10, 7))
colores = ['#DC2626' if v < 0 else '#0D9488' for v in top.values]
plt.barh(top.index, top.values, color=colores)
plt.axvline(0, color='black', linewidth=0.8)
plt.title('Cuánto suma o resta cada característica al precio (euros)')
plt.xlabel('Efecto en el precio')
plt.tight_layout()
plt.show()
```



```
[39]: print("--- Lo que más encarece ---")
print(coeficientes.tail(6).round(0).to_string())
```

```

print("\n--- Lo que más abarata ---")
print(coeficientes.head(6).round(0).to_string())
print("\n--- Efecto de las numéricas ---")
for v in ['Ram_GB', 'SSD_GB', 'PPI', 'Weight_kg']:
    print(f"{v:12s} {coeficientes[v]:+8.1f} euros por unidad")

```

--- Lo que más encarece ---

```

Company_Samsung      391.0
Company_Microsoft    417.0
Company_Google       476.0
TypeName_Workstation 594.0
Company_LG           719.0
Company_Razer        873.0

```

--- Lo que más abarata ---

```

TypeName_Notebook     -267.0
Company_Chui          -254.0
TypeName_Netbook      -148.0
Cpu_gama_Intel Pentium Quad -139.0
Cpu_gama_Intel Celeron Dual -121.0
Company_Mediacom      -117.0

```

--- Efecto de las numéricas ---

```

Ram_GB      +45.5 euros por unidad
SSD_GB      +0.7 euros por unidad
PPI         +2.4 euros por unidad
Weight_kg   +237.2 euros por unidad

```

Cada GB de RAM adicional suma unos euros al precio, cada GB de SSD también, y el PPI tiene un efecto claro. Del lado de las marcas, Razer y LG son las que más encarecen respecto a la marca base, y ser Workstation suma bastante.

Ojo con interpretar esto como causa. El modelo dice que los equipos Razer son más caros en promedio una vez descontadas las demás características, no que ponerle el logo de Razer a un portátil lo encarezca.

7.6 3.10 Probando el modelo con un caso concreto

Para que se entienda mejor, veamos qué predice para un equipo específico del conjunto de prueba.

```

[40]: i = 5
equipo = X_test.iloc[[i]]
real = y_test.iloc[i]
predicho = modelo.predict(equipo)[0]

# recuperamos las características originales de ese equipo
idx = X_test.index[i]
print("Equipo:", df.loc[idx, 'Company'], "|", df.loc[idx, 'TypeName'])
print("RAM:", df.loc[idx, 'Ram_GB'], "GB | SSD:", df.loc[idx, 'SSD_GB'], "GB")

```



```
print("Procesador:", df.loc[idx, 'Cpu_gama'])
print()
print(f"Precio real:      {real:.0f} euros")
print(f"Precio predicho: {predicho:.0f} euros")
print(f"Diferencia:      {abs(real - predicho):.0f} euros")
```

Equipo: HP | 2 in 1 Convertible
RAM: 8 GB | SSD: 256.0 GB
Procesador: Intel Core i5

Precio real: 1399 euros
Precio predicho: 1295 euros
Diferencia: 104 euros

8 PARTE 3: Conclusiones y aplicación

8.1 3.11 Qué encontramos

1. **Las características técnicas explican el 77% del precio.** No es todo, pero es la mayor parte. Existe una lógica bastante consistente en cómo se fijan los precios en este mercado.
2. **La RAM y el almacenamiento SSD son los que más pesan.** Fueron las correlaciones más altas y también los coeficientes más consistentes del modelo.
3. **El tamaño de pantalla es irrelevante, la calidad no.** Las pulgadas tienen correlación de 0.07 con el precio, pero el PPI tiene 0.47. Lo que se paga no es una pantalla grande sino una pantalla buena.
4. **El mercado está segmentado en gamas claras.** De Netbook a Workstation hay seis veces de diferencia en el precio mediano, y el procesador ordena el mercado casi perfectamente.
5. **El modelo se equivoca en promedio 234 euros.** Sobre un precio mediano de 977, es un error de alrededor del 24%. Sirve para estimar rangos, no para poner precios exactos.

8.2 3.12 Para qué sirve esto en la práctica

Un modelo así tiene usos concretos en el área de tecnología:

Compras corporativas. Cuando una empresa cotiza equipos para su personal, este modelo permite estimar cuánto debería costar un portátil con determinadas especificaciones. Si un proveedor cotiza muy por encima de la predicción, hay margen para negociar. Si cotiza muy por debajo, vale la pena revisar por qué.

Detección de oportunidades. Los equipos cuyo precio real está muy por debajo del predicho son candidatos a ser buenas compras: tienen mejores especificaciones de lo que su precio sugiere.

Definición de presupuestos. En lugar de pedir un presupuesto genérico, se puede justificar con datos: “un equipo con 16 GB de RAM y SSD de 512 para el área de desarrollo debería costar alrededor de X euros”.

Lo que el modelo no puede hacer. No sirve para predecir precios de equipos muy fuera del rango del dataset, ni captura el efecto del tiempo (los precios de tecnología bajan), ni incluye factores como garantía o servicio postventa, que en compras corporativas pesan bastante.

8.3 3.13 Limitaciones

Para ser honestos con el alcance de este trabajo:

- El dataset es una foto de un momento, no una serie de tiempo. No sabemos de cuándo son los precios ni cómo han cambiado.
- La regresión lineal asume que las relaciones son lineales. Probablemente no lo son del todo: pasar de 4 a 8 GB de RAM no cuesta lo mismo que pasar de 32 a 64.
- Algunas categorías tienen muy pocos equipos (21 Mac, 12 con procesador AMD A9), así que sus coeficientes no son muy confiables.
- Los precios están en euros y corresponden a un mercado que no necesariamente se comporta igual que el colombiano.

8.4 Resumen de la Etapa 3

Lo que hicimos:

- Visualizamos la relación entre las características y el precio, encontrando que la intuición sobre el tamaño de pantalla estaba equivocada
 - Convertimos las variables categóricas a formato numérico con one-hot encoding, pasando de 15 a 46 columnas
 - Entrenamos una regresión lineal múltiple con división 80/20
 - Obtuvimos R^2 de 0.77 y error promedio de 234 euros, sin sobreajuste
 - Interpretamos los coeficientes para entender qué aprendió el modelo
 - Planteamos aplicaciones concretas y fuimos explícitos sobre las limitaciones
-

9 Cierre del proyecto

9.1 El recorrido completo

Etapas 1. El dataset no tenía valores nulos ni duplicados, pero diez de sus trece columnas eran texto sin procesar. La RAM decía "8GB", el peso decía "1.37kg", y el almacenamiento mezclaba unidades y hasta dos discos en un mismo campo. El trabajo de limpieza consistió en convertir todo eso en información utilizable: quedamos con 18 variables y los 1.303 equipos intactos.

Etapas 2. El precio resultó estar sesgado hacia la derecha (asimetría de 1.52), así que la mediana representa mejor el valor típico que el promedio. El método del rango intercuartílico marcó 221 equipos como atípicos por RAM, pero al revisarlos eran portátiles Gaming y Workstation reales, no errores, así que los conservamos. La RAM y el SSD aparecieron como las variables más relacionadas con el precio.

Etapas 3. Convertimos las variables categóricas a formato numérico y entrenamos una regresión lineal múltiple. El modelo explica el 76.6% de la variación del precio con un error promedio de 234 euros, sin señales de sobreajuste.

9.2 La respuesta a la pregunta

Sí se puede predecir el precio de un portátil a partir de sus especificaciones, con bastante precisión para estimar rangos aunque no para fijar precios exactos.

Lo que más pesa es la memoria RAM y el almacenamiento SSD. Lo que no pesa, contra lo que uno pensaría, es el tamaño de la pantalla: lo que se paga no es una pantalla grande sino una pantalla buena.

9.3 Qué aprendimos haciendo esto

Que la mayor parte del trabajo en ciencia de datos no está en el modelo sino antes. La Etapa 1 fue la más larga y la menos vistosa, pero sin ella no había nada que analizar.

Y que los números hay que interpretarlos, no solo calcularlos. El disco duro tiene correlación negativa con el precio y el peso aparece sumando euros en el modelo; ninguna de las dos cosas significa lo que parece a primera vista.